



Análisis de datos

INFORMÁTICA INDUSTRIAL AVANZADA

MÁSTER INGENIERÍA INDUSTRIAL

PROFESOR: IVÁN TORRES

Índice

- ❑ Introducción
- ❑ Clustering
- ❑ Reducción de dimensionalidad
- ❑ Clasificadores probabilísticos
- ❑ Evaluación de rendimiento

Introducción

- ❑ ¿Qué es la IA?
 - ❑ Matemáticas y computer science
- ❑ Importancia de los datos
- ❑ Definir bien el problema
 - ❑ Clasificación
 - ❑ Forecasting
 - ❑ Regresión
 - ❑ ...

Introducción

- ❑ Los datos son nuestra entrada para el problema
 - ❑ Puede haber varios problemas
 - ❑ Escasos
 - ❑ Falta de datos concretos de una serie
 - ❑ ¿Cómo afrontar la falta de datos?
 - ❑ Eliminar
 - ❑ Rellenar con la media
 - ❑ Rellenar atendiendo a casos similares
 - ❑ Generación de datos sintéticos

Introducción

- ❑ Extracción de características
 - ❑ Obtener características relevantes que nos ayuden a entender los datos
- ❑ Clasificación en base a las características
- ❑ Obtención de la salida
- ❑ Enfoque del machine learning
 - ❑ Input → Feature Extraction → Classification → Output
- ❑ Enfoque del Deep learning
 - ❑ Input → Feature Extraction + Classification → Output


Clustering

❑ ¿En qué consiste?

❑ Tipos

❑ No supervisado → Sin etiquetas


❑ Supervisado → Con etiquetas



Clustering

□ K-Means

- Se asignan las observaciones al centroide más cercano el proceso se repite hasta que los centroides no varían
- Hay que especificar el número de clusters en los que agrupamos la información
- Los centroides iniciales pueden ser aleatorios o a base de información previa
- Calculamos la distancia euclídea entre cada observación y cada centroide, y le asignamos a cada observación la etiqueta del centroide más cercano.
- Una vez hayamos asignado una etiqueta a cada observación, calculamos el nuevo centroide de cada clase.
- Repetimos el procedimiento hasta que los centroides no se muevan.



Clustering

□ Hierarchical clustering

- se genera una secuencia de particiones de las observaciones hasta conseguir el número de clases deseadas. Hay 2 tipos: divisiva y aglomerativa.
- Divisiva: se empieza con las observaciones agrupadas en 1 solo conjunto. Se sigue dividiendo el cluster secuencialmente hasta alcanzar el número de clases deseado
- Aglomerativo: al igual que el k-mean necesitamos especificar el número de cluster que queremos.
 - [1] Specify the number of clusters k to be found in data.
 - [2] Initialize the number of clusters to the number of observations N .
 - [3] Group the nearest two clusters based on a cluster-to-cluster distance.
 - [4] Recompute the centroid of each cluster from the assigned observations
 - [5] Repeat steps 3-4 until the number of clusters is k .



Clustering

- Cluster-to-cluster distance

- Considerando dos clusters r y s con n_r y n_s observaciones. Una forma común de medir la distancia de cluster a cluster es:

$$d_{min}(r, s) = \min\{d(x_i^r, x_j^s)\}, i = 1, \dots, n_r; j = 1, \dots, n_s$$

- Donde $d(x_i^r, x_j^s)$ es la distancia euclídea entre la observación i del cluster r y la j en el cluster s .

Clustering

☐ Gaussian Mixture Models


- ☐ Se modelan las observaciones usando una mezcla de distribuciones normales multivariable (Gaussian Mixture Models). La mezcla se realiza haciendo una suma pesada de distribuciones normales centradas en diferentes puntos.
- ☐ El número de clusters puede introducirse manualmente (es lo mismo a especificar un número de gaussianas) o se pueden usar criterios de ajuste como el Bayesian Information Criterion (BIC). $BIC = -\text{error} + \text{complexity}$
- ☐ Inconveniente: se necesitan muchas observaciones para ajustar un GMM.
- ☐ Procedimiento:
 - ☐ Ajustar varios GMM con diferente número de componentes (medias)
 - ☐ Calcular el BIC para cada modelo
 - ☐ Escoger el modelo con menor BIC (¡OJO! es negativo, así que el más negativo)
 - ☐ El mejor modelo es el que usaremos para predecir la clase a la que pertenece cada observación
- ☐ Definir diferentes varianzas para cada cluster puede mejorar el ajuste de los GMM. El caso más simple sería tener la misma varianza para todos los clusters.

Principio de parsimonia

- ❑ El principio de parsimonia (Parsimony Principle) dice que la performance del modelo se enfrenta con su complejidad. Cuanto más complejo es un modelo mejor ajuste tendrá a las observaciones, pero será menos general y el modelo perderá capacidad de predicción. (Overfitting)
- ❑ El Bayesian Information Criterion (BIC) y el Akaike Information Criterion (AIC) son Parsimony Index

Parameter estimation

- Consiste en estimar los parámetros del modelo a partir de unas observaciones. Los parámetros dependen del tipo de modelo (en el caso de los GMM serían las medias)



Dimensionality reduction

- ❑ ¿En qué consiste?
- ❑ Matriz de datos $A(N \times M)$: N #observations, M #features
 - ❑ Principal components analysis (PCA)
 - ❑ Visualization of high dimensional data (Not robust enough for machine learning)
 - ❑ MDS
 - ❑ t-SNE
 - ❑ Feature selection methods
 - ❑ Independent component analysis (ICA) → Identify independent sources in data

Dimensionality reduction


- ❑ Principal component analysis
- ❑ PC1 → Identifica la dirección de más variabilidad en los datos. First principal component.
- ❑ Los PC (principal components), vienen dados por autovectores $v_1, v_2, \dots$. Los autovalores de estos dan cuanta variabilidad es explicada por $v_1, v_2, \dots$. En este punto tenemos m dimensiones, pero se pueden proyectar los datos al PC1.
- ❑ Si $A(n,m)$ habrá m eigenvalues
- ❑ ¿Cuántos necesitamos?

Dimensionality reduction

- ❑ Principal component analysis
- ❑ PC1 → Identifica la dirección de más variabilidad en los datos. First principal component.
- ❑ Los PC (principal components), vienen dados por autovectores $v_1, v_2, \dots$. Los autovalores de estos dan cuanta variabilidad es explicada por $v_1, v_2, \dots$. En este punto tenemos m dimensiones, pero se pueden proyectar los datos al PC1.
- ❑ Si $A(n,m)$ habrá m eigenvalues
- ❑ ¿Cuántos necesitamos? Necesitamos hasta que lleguemos al 95% de varianza acumulativa explicada.
- ❑ **Python:** `pca.explained_variance_ratio` → Da la varianza de los componentes
- ❑ **Python:** `pca.components` da los eigenvectors

Dimensionality reduction

- ❑ Principal component analysis
- ❑ Se puede aplicar a imágenes, pero hay que hacer un flatten



(a) 1 principal component



(b) 5 principal component



(c) 9 principal component



(d) 13 principal component



(e) 17 principal component



(f) 21 principal component




(g) 25 principal component



(h) 29 principal component

Dimensionality reduction

- ❑ Independent component analysis
- ❑ Se usa cuando queremos separar señales que con una sola fuente sería complicado separar.
- ❑ Se asume que las fuentes son estadísticamente independientes y que cada fuente sigue una distribución no Gaussiana
- ❑ 5 personas hablando → Necesitamos 5 micrófonos
- ❑ Noise cancel
- ❑ $x = \alpha \cdot S$
- ❑ $X \rightarrow$ mixture; $\alpha \rightarrow$ weights; $S \rightarrow$ sources



Shannon's entropy

❑ Física: Medida del desorden de un sistema

$$S = k \log W$$

❑ Contenido de información

❑ Conjunto de símbolos (Alfabeto): $a_1, a_2, \dots, a_n$

❑ Probabilidad de ocurrencia de cada símbolo en un mensaje: $p_1, p_2, \dots, p_n$

❑ $S = \sum_{i=1}^n p_i \log(p_i)$

❑ Ejemplo: Imagen en escala de grises


❑ Alfabeto: Niveles de intensidad de gris: $0, 1, 2, 3, \dots, 255$

❑ Probabilidad de ocurrencia: Histograma: $p_1, p_2, \dots, p_n$

❑ Baja entropía → Menos bits para codificar la imagen → Compresión de imagen

$S = 6.9439$ bits/pixel

$S = 8$ bits/pixel



Probabilistic classifiers

- ❑ Es una técnica supervisada que requiere de un conjunto de entrenamiento
- ❑ Train = Identify parameters = Fit = Parameter estimation (Inference)
- ❑ El objetivo es que ante una observación X_{new} el clasificador devuelva la clase w a la que pertenece
 - ❑ Tipos de clasificadores:
 - ❑ Discriminant analysis
 - ❑ Naive Bayes
 - ❑ Linear Gaussian Discriminant
 - ❑ KNN: K-nearest neighbours
 - ❑ Decision trees

Evaluación de rendimiento

- ❑ Métricas de rendimiento
 - ❑ Uso de set de entrenamiento (70%) y de prueba (30%)
 - ❑ Se compara los valores estimados por el método utilizado con el valor real
 - ❑ En el caso particular de un problema de clasificación con dos clases
 - ❑ Errores tipo 1 → Falsa alarma
 - ❑ Errores tipo 2 → Omisión
- ❑ Cuando queremos validar un modelo se suele usar cross-validation
 - ❑ Se entrenan modelos en subsets aleatorios y se validan con los subsets restantes
 - ❑ La performance del modelo se calcula como la media del rendimiento en los diferentes subsets

Evaluación de rendimiento

Confusion Matrix

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

Evaluación de rendimiento

$$TPR = \frac{TP}{\text{Actual Positive}} = \frac{TP}{TP + FN} \quad \text{Recall}$$

$$FNR = \frac{FN}{\text{Actual Positive}} = \frac{FN}{TP + FN}$$

$$TNR = \frac{TN}{\text{Actual Negative}} = \frac{TN}{TN + FP} \quad \text{Specificity}$$

$$FPR = \frac{FP}{\text{Actual Negative}} = \frac{FP}{TN + FP}$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Evaluación de rendimiento

□ K-Fold cross validation

